



上海海事大学
SHANGHAI MARITIME UNIVERSITY

自然语言处理

2024–2025 学年第 2 学期



信息工程学院 谢雨波

预训练语言模型

- **掩码语言模型 (Masked Language Model)**
 - Transformer 编码器 (Encoder-Only)
 - BERT, RoBERTa, ERNIE, ALBERT, DeBERTa, ...
- **因果语言模型 (Causal Language Model)**
 - Transformer 解码器 (Decoder-Only)
 - GPT, PaLM, Mistral (Mixtral), Llama, DeepSeek, ...
- **编码器-解码器语言模型 (Encoder-Decoder Language Model)**
 - BART, T5, ...


掩码语言模型

掩码语言模型


- **掩码语言模型 (Masked Language Model)**
 - 预训练语言模型的一种范式
 - 通常采用双向 Transformer 编码器 (Bidirectional Transformer Encoder)
- **相关概念:**
 - 微调 (Fine-tuning) 、迁移学习 (Transfer Learning)
 - 上下文嵌入 (Contextual Embedding)

双向 Transformer 编码器

- 相比较于单向的注意力机制，双向注意力：
 - 可以获取当前词之后的词的信息
 - 更适合于文本分类、序列标注



单向注意力



双向注意力

BERT

Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova.
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL 2019.

- **Bidirectional Encoder Representations from Transformers (BERT)**
- 子词词表大小 30,000 (WordPiece)

BERT_{BASE}

隐藏状态大小 768

12 层 Transformer 层

12 头注意力

参数量 110M


BERT_{LARGE}

隐藏状态大小 1024

24 层 Transformer 层

16 头注意力

参数量 340M



训练 BERT


- 任务 1：掩码语言模型（Masked LM）
 - “完形填空”（Cloze Task）
 - 输入序列的一部分是缺失的，模型需要预测缺失的部分

Please hand in ? homework .

掩码语言模型

- 掩码语言模型 (**Masked Language Model, MLM**)
- 在 BERT 中，随机从一个训练序列中选择 Token (15%)，然后进行以下操作中的一种：
 - 将其替换为特殊词 **[MASK]** 80%
 - 将其替换为词表中的一个其他词（根据概率随机采样）10%
 - 保持不变 10%

掩码语言模型



掩码语言模型

- 对于某一输入词 x_i (替换前) , z_i 为 BERT 的输出

$$L_{\text{MLM}} = - \log P(x_i | z_i)$$

- 令 M 为选中的 Token 集合

$$L_{\text{MLM}} = - \frac{1}{|M|} \sum_{i \in M} \log P(x_i | z_i)$$


训练 BERT

- 任务 2：下一语句预测（**Next Sentence Prediction, NSP**）
 - 有些 NLP 任务需要确定一对语句之间的关系
 - 释义识别（**Paraphrase Detection**）：两个语句是否有相似的意思
 - 文本蕴含（**Textual Entailment**）：给定前文本，推断假说文本与其的关系，一般有蕴含关系（Entailment）和矛盾关系（Contradiction）
 - 语篇连贯性（**Discourse Coherence**）：两个语句是否来自同一语篇的相邻句子

下一语句预测


- 在 BERT 中，训练样本为**语句对 (Sentence Pair)**
 - 目标为预测输入的语句对是否来自于训练语料库中的相邻语句，或是无关的语句对
 - 50% 为正向样本，50% 为负向样本（随机挑选的两个句子）
 - 两个新的 Token：[CLS] 和 [SEP]

下一语句预测



下一语句预测

- 基于 [CLS] 的输出，进行二元分类预测



BERT 训练

- 训练集：
 - BookCorpus + Wikipedia (33 亿单词，包含英语维基百科与书籍语料库)
 - BookCorpus 因版权原因，不再被使用
- 输入序列长度上限：512
- 训练 Epoch 数目：~40

多语言模型训练

- 如何建立一个多语言的词表（使用 BPE 等子词分词算法）？
- 从训练语料库中随机采样句子，进行分词，得到词表
 - 结果将更偏向于常见语言的罕见词
 - 而不是罕见语言的常见词
- 因此，需要对语种的概率分布进行调整

多语言模型训练

- 将训练语料库基于语种分为 N 个子语料库
- 对于语种 i , 语料库中有 n_i 个句子
- 从语种 i 中挑选句子的概率为

$$q_i = \frac{p_i^\alpha}{\sum_{j=1}^N p_j^\alpha} \quad p_i = \frac{n_i}{\sum_{j=1}^N n_j}$$

- 0 和 1 之间的 α 值将增加低概率事件的概率值, 此处一般取 $\alpha = 0.3$

多语言模型训练

- 为什么训练一个多语言模型?
 - 不需要为每一种语言训练一个单独的模型
 - 低资源语言 (Low-Resource Language) 的模型效果可以通过语料库中相似语言的训练样本来进行改善
- **Curse of Multilinguality**: 当训练的语言数目增长至非常大时, 每一种语言的模型效果将降低 (Conneau et al., 2020)
- 由于各语言资源的不平衡, 高资源语言 (如英语) 的某些语法结构将呈现在低资源语言上 (Papadimitriou et al., 2023)

上下文嵌入

上下文嵌入

- BERT 模型为输入序列的每一个词 x_i 输出一个向量表示 z_i
- 此向量表示是输入词的上下文嵌入 (**Contextual Embedding**) 表示
 - 在 x_1, \dots, x_n 的上下文中，词 x_i 的语义表示
 - 也可以将模型后 4 层的输出 z_i 进行平均
- 是一种动态的词嵌入，相较于 word2vec 的静态词嵌入

上下文嵌入与词义

- 单词是具有歧义的，即一个单词可能有多种词义 (**Word Sense**)
- 可以根据上下文来确定一个单词的词义
 - **mouse¹** : ... a *mouse* controlling a computer system in 1968.
 - **mouse²** : ... a quiet animal like a *mouse*
 - **bank¹** : ... a *bank* can hold the investments in a custodial account ...
 - **bank²** : ... as agriculture burgeons on the east *bank*, the river ...

上下文嵌入与词义

Coenen, A., E. Reif, A. Yuan, B. Kim, A. Pearce, F. Viégas, and M. Wattenberg. Visualizing and measuring the geometry of BERT. NeurIPS 2019.

German article “die”

德语定冠词

Was der Fall ist, **die** Tatsache,
ist das Bestehen von Sachverhalten.

über **die** Verhandlungen
der Königl.

“死亡”

single person dies

Chernenko became the first Soviet
leader to **die** in less than three years

Vaughan's ultimate fantasy was to **die** in a
head-on collision with movie star Elizabeth Taylor


multiple people die

Over 60 people **die** and over
100 are unaccounted for.

Many more **die** from radiation
sickness, starvation and cold.

“骰子”

a playing die




Players must always move a
token according to the **die** value

The faces of a **die** may be placed
clockwise or counterclockwise

词义消歧

- 词义消歧 (Word Sense Disambiguation, WSD)

- 为输入单词选择正确的词义



词义消歧

1-邻近算法 (1-Nearest-Neighbor Algorithm)


- 将词义标注数据集（如 SemCore 和 SenseEval）输入 BERT 获得每一个标注词的上下文嵌入
- 对于语料库中任一词的每一个词义 s , 对符合词义 s 的 n 个词的上下文嵌入 v_i 进行平均得到词义 s 的上下文嵌入：

$$v_s = \frac{1}{n} \sum_i v_i \quad \forall v_i \in \text{tokens}(s)$$

词义消歧

- 对于测试词 t , 计算它的上下文嵌入和每一个词义嵌入的相似度, 选择相似度最高的词义作为返回结果

$$\text{sense}(t) = \underset{s \in \text{senses}(t)}{\operatorname{argmax}} \cos(t, v_s)$$



微调

微调


- 将预训练语言模型用于特定的下游任务
- 微调（**Fine-tuning**）
 - 在预训练模型的基础上增加少量与特定任务相关的参数
 - 使用特定任务的标注数据对这些参数进行训练
 - 通常会保持原预训练模型的参数不变，或仅做少量调整（例如，仅调整原预训练模型的最后几层参数）

序列分类

- 在对输入序列进行分类时，通常将输入序列表示为一个向量
 - 例如，RNN 中的最后一个隐藏状态
- 在 BERT 中，可以使用 [CLS] 的输出向量 z_{CLS} 表示整个输入序列
 - 也称为句子嵌入 (**Sentence Embedding**)
 - 将其输入一个分类头 (**Classifier Head**) 进行分类：

$$y = \text{softmax}(W_C z_{\text{CLS}})$$

序列分类



成对序列分类

- 成对序列分类 (**Pairwise Sequence Classification**)
 - 输入由 A 和 B 两个句子组成
 - 释义识别 (Paraphrase Detection) : A 和 B 是否是对方的转述?
 - 文本蕴含 (Textual Entailment) : A 是否在逻辑上蕴含 B?
 - 语篇连贯性 (Discourse Coherence) : B 接在 A 后面是否连贯?


成对序列分类

- 例如，文本蕴含任务又称自然语言推断 (**Natural Language Inference, NLI**)
- Multi-Genre Natural Language Inference (MultiNLI) 数据集
- 句子对：前提 (Premise) + 假设 (Hypothesis)
- 有 3 个标签： *entails*, *contradicts*, *neutral*

- Neutral
 - a: Jon walked back to the town to the smithy.
 - b: Jon traveled back to his hometown.
- Contradicts
 - a: Tourist Information offices can be very helpful.
 - b: Tourist Information offices are never of any help.
- Entails
 - a: I'm confused.
 - b: Not all of it is very clear to me.

成对序列分类

- 模型结构和 NSP 相同




序列标注

- 序列标注 (Sequence Labeling)
 - 词性标注 (Part-Of-Speech Tagging)
 - 命名实体识别 (Named Entity Recognition, NER)
- 每一个输入词的输出向量都用于预测标签

$$y_i = \text{softmax}(W_K z_i)$$

$$t_i = \underset{k}{\operatorname{argmax}}(y_i)$$

序列标注



BERT 相关模型

RoBERTa

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, Veselin Stoyanov.
RoBERTa: A Robustly Optimized BERT Pretraining Approach. 2019.

- **RoBERTa (Robustly optimized BERT approach)**
- **训练数据更多**: BookCorpus, CC-News, OpenWebText, Stories, 共计 160GB
- **动态掩码**: 每次将序列输入模型时, 进行掩码操作, 而不是在数据预处理时进行掩码操作

Masking	SQuAD 2.0	MNLI-m	SST-2
reference	76.3	84.3	92.8
<i>Our reimplementation:</i>			
static	78.3	84.3	92.5
dynamic	78.7	84.0	92.9

RoBERTa

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, Veselin Stoyanov.
RoBERTa: A Robustly Optimized BERT Pretraining Approach. 2019.

- **去除 NSP 任务：**在去除 NSP 损失后，发现模型在下游任务上的效果稍稍变好
- 可能的原因：NSP 任务较为简单：**Topic Prediction + Coherence Prediction**；原 BERT 论文在去除 NSP 后，依旧保留了 Segment-Pair 的输入格式

Model	SQuAD 1.1/2.0	MNLI-m	SST-2	RACE
<i>Our reimplementation (with NSP loss):</i>				
SEGMENT-PAIR	90.4/78.7	84.0	92.9	64.2
SENTENCE-PAIR	88.7/76.2	82.9	92.1	63.0
<i>Our reimplementation (without NSP loss):</i>				
FULL-SENTENCES	90.4/79.1	84.7	92.5	64.8
DOC-SENTENCES	90.6/79.7	84.7	92.7	65.6
BERT _{BASE}	88.5/76.3	84.3	92.8	64.3
XLNet _{BASE} (K = 7)	-/81.3	85.8	92.7	66.1
XLNet _{BASE} (K = 6)	-/81.0	85.6	93.4	66.7

RoBERTa

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, Veselin Stoyanov.
RoBERTa: A Robustly Optimized BERT Pretraining Approach. 2019.

- 使用 BPE 算法进行分词，词表大小为 50K
 - 分词单位为字节 (Byte) , 而不是 Unicode 字符
 - 可以将词表控制在一个合适的大小，同时泛化能力更强
- 增大 Batch Size

bsz	steps	lr	ppl	MNLI-m	SST-2
256	1M	1e-4	3.99	84.7	92.7
2K	125K	7e-4	3.68	85.2	92.9
8K	31K	1e-3	3.77	84.6	92.8

ALBERT

Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel,
Piyush Sharma, Radu Soricut. [ALBERT: A Lite BERT for Self-supervised
Learning of Language Representations](#). ICLR 2020.

- ALBERT: A Lite BERT, BERT 的轻量化版本
- 嵌入矩阵分解：不直接将输入的独热向量映射到模型的隐藏状态大小 H , 而是先映射到较低维度的空间（大小为 E ）, 然后再映射到 H
$$O(V \times H) \rightarrow O(V \times E + E \times H) \quad H \gg E$$
- 将所有的 Transformer 层的参数共享
- 去除 NSP, 加入句子顺序预测 (Sentence-Order Prediction, SOP)
- **ALBERT-large: 60M** (BERT-large: 340M)

DistilBERT

Victor Sanh, Lysandre Debut, Julien Chaumond, Thomas Wolf.
DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. NeurIPS 2019 Workshop.

- 对 BERT 模型进行压缩
- 知识蒸馏 (**Knowledge Distillation**)
 - Teacher: 原 BERT 模型
 - Student: 基本结构和 BERT 相同, 层数减少 1/2 (去掉 Segment Embedding)
 - 参数量减少 40%, 速度提升 60%, 性能达到原 BERT 的 97%