



上海海事大学  
SHANGHAI MARITIME UNIVERSITY

# 自然语言处理


2024–2025 学年第 2 学期



信息工程学院 谢雨波

# 神经网络

# (你脑子里的) 神经元



# (神经网络里的) 神经元


输出

非线性转换

加权和

权重

输入层



# 神经元

- 计算输入的加权和（加上一个偏置）

$$z = b + \sum_i w_i x_i$$

$$z = w \cdot x + b$$


- 然后在  $z$  的基础上进行非线性转换（激活函数）

$$y = a = f(z)$$

# 非线性激活函数

- 例如 sigmoid 函数

$$y = \sigma(z) = \frac{1}{1 + e^{-z}}$$



# 神经元


输出

非线性转换

加权和


权重

输入层




# 其他非线性激活函数

(最常用)



tanh



ReLU: Rectified Linear Unit

# XOR 问题

- 神经元可以拟合输入的简单函数吗？

AND		OR		XOR	
x1	x2	y	x1	x2	y
0	0	0	0	0	0
0	1	0	0	1	1
1	0	0	1	0	1
1	1	1	1	1	0

# 感知器


- 感知器 (**Perceptron**) : 一个非常简单的神经元
  - 二元输出
  - 没有非线性激活函数

$$y = \begin{cases} 0, & \text{if } w \cdot x + b \leq 0 \\ 1, & \text{if } w \cdot x + b > 0 \end{cases}$$

# 使用感知器解决 AND 问题

$$y = \begin{cases} 0, & \text{if } w \cdot x + b \leq 0 \\ 1, & \text{if } w \cdot x + b > 0 \end{cases}$$


AND		y
x <sub>1</sub>	x <sub>2</sub>	
0	0	0
0	1	0
1	0	0
1	1	1



# 使用感知器解决 OR 问题

$$y = \begin{cases} 0, & \text{if } w \cdot x + b \leq 0 \\ 1, & \text{if } w \cdot x + b > 0 \end{cases}$$

OR		y
x <sub>1</sub>	x <sub>2</sub>	
0	0	0
0	1	1
1	0	1
1	1	1




# 感知器无法解决 XOR 问题

- 感知器是线性分类器
  - 给定  $x_1$  和  $x_2$ , 决策边界是一条直线:


$$w_1x_1 + w_2x_2 + b = 0$$

- 如果输入在直线的一边, 则输出 0
- 如果输入在直线的另一边, 则输出 1


# 决策边界



$x_1 \text{ AND } x_2$



$x_1 \text{ OR } x_2$




$x_1 \text{ XOR } x_2$



# XOR 问题

- XOR 问题不能用单个感知器解决
- 但是可以用多层网络结果的感知器解决


XOR		y
x1	x2	
0	0	0
0	1	1
1	0	1
1	1	0



# 隐藏层表示 $h$




$x$  空间




$h$  空间

# 前馈神经网络


- 前馈神经网络 (**Feedforward Neural Network**)
  - 也被称为多层感知器 (**Multi-Layer Perceptron, MLP**)



# 二元逻辑回归



# 多元逻辑回归




# softmax 函数

- sigmoid 函数的一般情况
- 对于  $z \in \mathbb{R}^k$

$$\text{softmax}(z) = \left[ \frac{\exp(z_1)}{\sum_{i=1}^k \exp(z_i)}, \frac{\exp(z_2)}{\sum_{i=1}^k \exp(z_i)}, \dots, \frac{\exp(z_k)}{\sum_{i=1}^k \exp(z_i)} \right]$$

$$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^k \exp(z_j)}$$

# 多层神经网络



$$y = a^{[2]}$$

$$a^{[2]} = g^{[2]}(z^{[2]}) \quad \text{sigmoid/softmax}$$


$$z^{[2]} = W^{[2]}a^{[1]} + b^{[2]}$$

$$a^{[1]} = g^{[1]}(z^{[1]}) \quad \text{ReLU}$$

$$z^{[1]} = W^{[1]}a^{[0]} + b^{[1]}$$

$$a^{[0]} = x$$

# 多层神经网络



$$y = a^{[2]}$$

$$a^{[2]} = g^{[2]}(z^{[2]}) \quad \text{sigmoid/softmax}$$


$$z^{[2]} = W^{[2]}a^{[1]}$$

$$a^{[1]} = g^{[1]}(z^{[1]}) \quad \text{ReLU}$$

$$z^{[1]} = W^{[1]}a^{[0]}$$

$$a^{[0]} = x$$

# 多层神经网络



$$a^{[0]} = x$$

**for**  $l$  **in**  $1..n$ :

$$z^{[l]} = W^{[l]} a^{[l-1]}$$

$$a^{[l]} = g^{[l]}(z^{[l]})$$

$$\hat{y} = a^{[n]}$$

# 神经网络的训练

# 梯度下降

- 梯度下降 (Gradient Descent)
  - 选择初始参数
  - 计算梯度：在当前参数值处计算目标函数的梯度
  - 更新参数：沿着负梯度方向更新参数

$$\theta^{t+1} = \theta^t - \eta \nabla L(\theta^t)$$

- 重复迭代

# 反向传播

- 反向传播 (**Backpropagation**)
  - 核心：链式法则 (**Chain Rule**)
  - 反向传播算法的步骤：
    1. 前向传播：输入数据，计算  $z^{[l]}, a^{[l]}$ ，以及损失函数  $L$
    2. 反向传播：使用链式法则计算参数  $W$  的梯度
    3. 参数更新

# 反向传播

- 计算参数  $W_{ji}^{[l]}$  的梯度

$$\frac{\partial L}{\partial W_{ji}^{[l]}} = \frac{\partial L}{\partial z_j^{[l]}} \frac{\partial z_j^{[l]}}{\partial W_{ji}^{[l]}}$$

$$= \frac{\partial L}{\partial z_j^{[l]}} a_i^{[l-1]}$$

$$\text{令 } \delta_j^{[l]} = \frac{\partial L}{\partial z_j^{[l]}} \quad \frac{\partial L}{\partial W_{ji}^{[l]}} = \delta_j^{[l]} a_i^{[l-1]}$$

$$a^{[0]} = x$$

**for**  $l$  **in**  $1..n$ :

$$z^{[l]} = W^{[l]} a^{[l-1]}$$

$$a^{[l]} = g^{[l]}(z^{[l]})$$

$$\hat{y} = a^{[n]}$$

# 反向传播

$$\delta_j^{[l]} = \frac{\partial L}{\partial z_j^{[l]}}$$

$$\delta_j^{[n]} = \frac{\partial L}{\partial a_j^{[n]}} \frac{\partial a_j^{[n]}}{\partial z_j^{[n]}} = \frac{\partial L}{\partial a_j^{[n]}} g^{[n]\prime}(z_j^{[n]}) \quad \checkmark$$

$$\delta_j^{[l]} = \sum_k \frac{\partial L}{\partial z_k^{[l+1]}} \frac{\partial z_k^{[l+1]}}{\partial z_j^{[l]}} = \sum_k \delta_k^{[l+1]} W_{kj}^{[l+1]} g^{[l]\prime}(z_j^{[l]})$$

(偏导的链式法则)

```
a[0] = x  
for l in 1..n:  
    z[l] = W[l] a[l-1]  
    a[l] = g[l](z[l])  
ŷ = a[n]
```




# 前馈神经网络的 NLP 应用

# 文本分类：情感分析

- 输入  $x$  为手动设计的特征，例如：

$$\begin{aligned}x_1 & \quad \text{count(positive lexicon) } \in \text{doc}) \\x_2 & \quad \text{count(negative lexicon) } \in \text{doc}) \\x_3 & \quad \begin{cases} 1 & \text{if “no” } \in \text{doc} \\ 0 & \text{otherwise} \end{cases} \\x_4 & \quad \text{count(1st and 2nd pronouns } \in \text{doc}) \\x_5 & \quad \begin{cases} 1 & \text{if “!” } \in \text{doc} \\ 0 & \text{otherwise} \end{cases} \\x_6 & \quad \log(\text{word count of doc})\end{aligned}$$

# 文本分类：情感分析




# 表征学习

- 类似于 word2vec 模型，从训练集中学习单词的表征：
  - 输入为  $n$  个单词的文本  $w_1, \dots, w_n$
  - 将文本表示为  $n$  个词嵌入  $e(w_1), \dots, e(w_n)$  (神经网络的参数)
  - 平均之后作为神经网络的输入：

$$x_{\text{mean}} = \frac{1}{n} \sum_{i=1}^n e(w_i)$$

# 表征学习



# 预训练

- $e(w_i)$  可以随机初始化
- $e(w_i)$  也可以初始化为 word2vec 或 GloVe 词嵌入
  - 预训练（Pre-training）
    - 在大量数据上训练模型，学习通用特征
    - 是深度学习与大语言模型的核心思想

# 神经语言模型

- 神经语言模型 (Neural Language Model)


$$P(w_t | w_1, \dots, w_{t-1}) \approx P(w_t | w_{t-N+1}, \dots, w_{t-1})$$

- 相较于  $N$  元语法模型：


- 能处理更长的历史文本
- 泛化能力更强 (能处理相似单词)
- 单词的预测能力更强

# 神经语言模型

- 将前  $N - 1$  个单词表示为独热向量 (One-hot Vector)
    - 向量中，单词的词典索引位置为 1，其他元素都是 0
  - 将独热向量与嵌入矩阵  $E$  相乘，得到词的向量表示



# 神经语言模型



# 神经语言模型的训练

